UNIVERSIDAD DE PALERMO | FACULTAD DE INGENIERÍA
Maestría en Inteligencia Artificial — Asignatura: Big Data

PROCESAMIENTO DISTRIBUIDO Y ANALÍTICA PREDICTIVA DE ACCIDENTES VIALES EN EE. UU. (2016–2023)

Evaluación Masiva de 7.72M de Registros: Índices Espaciales, Optimización Parquet, Consultas de Alta Complejidad y Pipeline Distribuido Spark MLlib

---

INTEGRANTES (GRUPO 4): Juan Diego Weber | Diego | Melisa
DOCENTES: Cátedra de Big Data • Defensa Oral de Proyecto Final • Octubre 2026

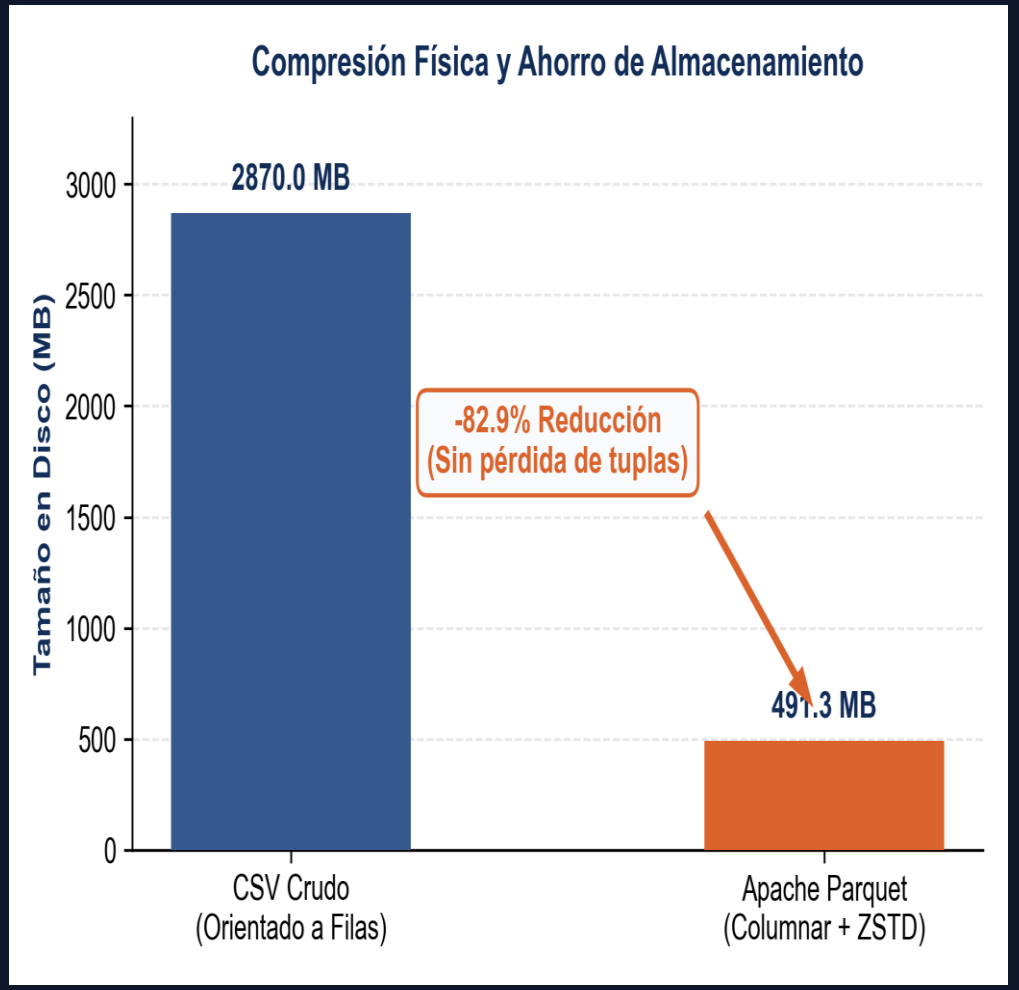
Dataset, Arquitectura y Especificaciones del Entorno de Cómputo

CARACTERÍSTICAS DEL DATASET Y PIPELINE I/O

- **Dataset US Accidents (2016–2023):**
  - 7,728,394 tuplas y 46 atributos heterogéneos (temporales, meteorológicos, viales).
  - Formato original CSV de 2.87 GB (2,940 MB) sin tipado estricto.

- Optimización de Almacenamiento Columnar:
  - Conversión a Apache Parquet con compresión ZSTD: 491.33 MB (-82.9% en disco).
  - Sorting físico por (Start_Lat, Start_Lng): clusteriza geográficamente los row groups.
  - Predicate Pushdown: Lectura de solo columnas necesarias con pruning a nivel metadata.

- Especificaciones del Entorno de Cómputo:
  - Apache Spark 3.5.0 en PySpark sobre OpenJDK 11 (64-bit).
  - Motor local / Google Colab T4, Python 3.11, Pandas 2.2 con PyArrow 14.
  - Pipeline modular reproducible con soporte nativo multiplataforma.

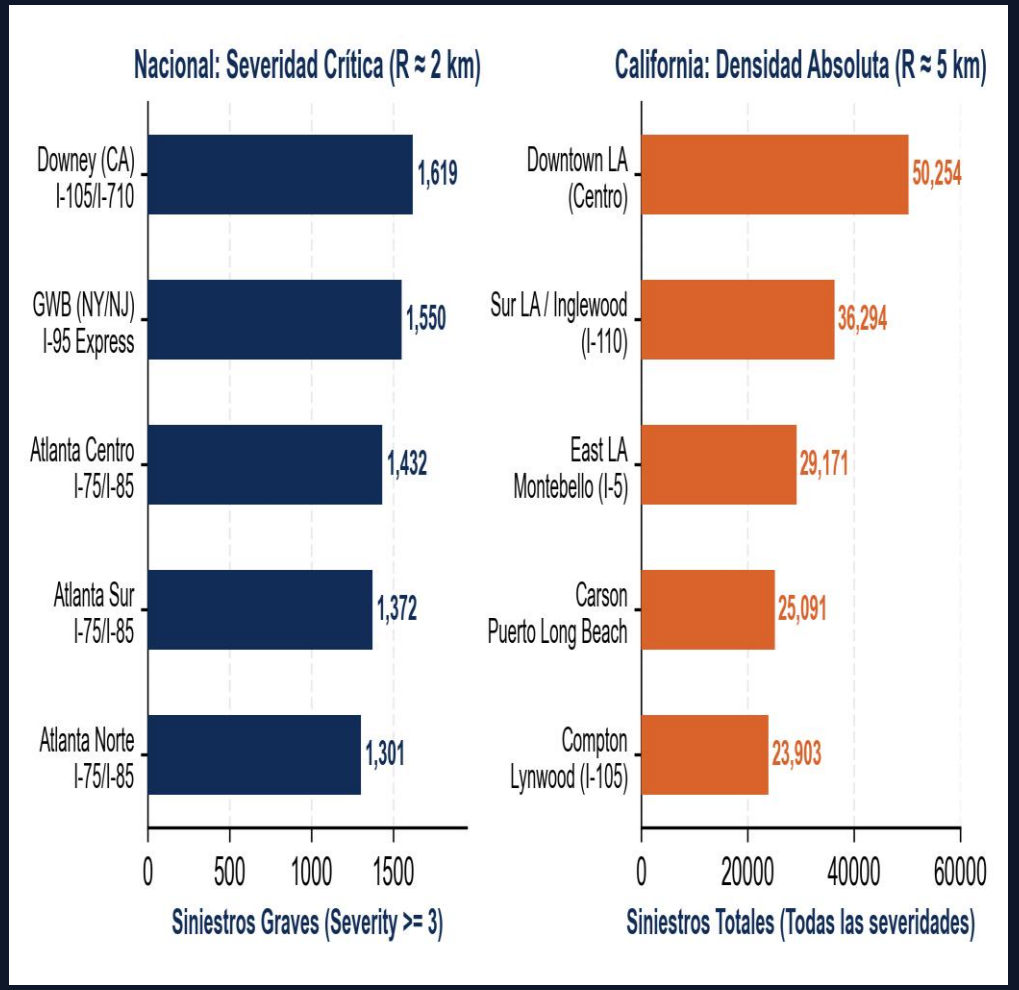


Consultas Analíticas (Parte 1): Análisis Espacial y Hotspots Críticos (C3 y C4)

SÍNTESIS DE C3 Y C4: HAVERSINE Y HOTSPOTS

• **Consulta 3 — Filtro Geodésico Paramétrico (Haversine R = 25 km):**
- Los Ángeles (34.05, -118.24): 361,038 siniestros detectados en 1.67 s.
- New York (40.71, -74.00): 269,717 siniestros (conglomerado a 105 m en Manhattan).
- Speedup Pandas (1.67 s) vs Spark (8.83 s): Pandas vectorizado en RAM supera el shuffle.

• Consulta 4 — Hotspots de Peligrosidad (DESTACADA OBLIGATORIA):
- ENFOQUE A (Severidad Crítica Nacional >= 3, Grilla ~2.2 km):
  Prioriza riesgo vital e impacto hospitalario:
  #1 Downey/LA (33.94, -118.10) con 1,619 | #2 George Washington Br. NY (40.85, -73.94) con 1,550
  #3-#5 Nodos I-75/I-85 en Atlanta (1,432, 1,372 y 1,301 siniestros graves).
- ENFOQUE B (Densidad Absoluta Urbana, Grilla ~5 km):
  Mide saturación vehicular: Top 1 en Downtown LA (34.05, -118.25) con 50,254 choques.



Consultas Analíticas (Parte 2): Corredores Viales y Detección de Anomalías (C6 y C8)

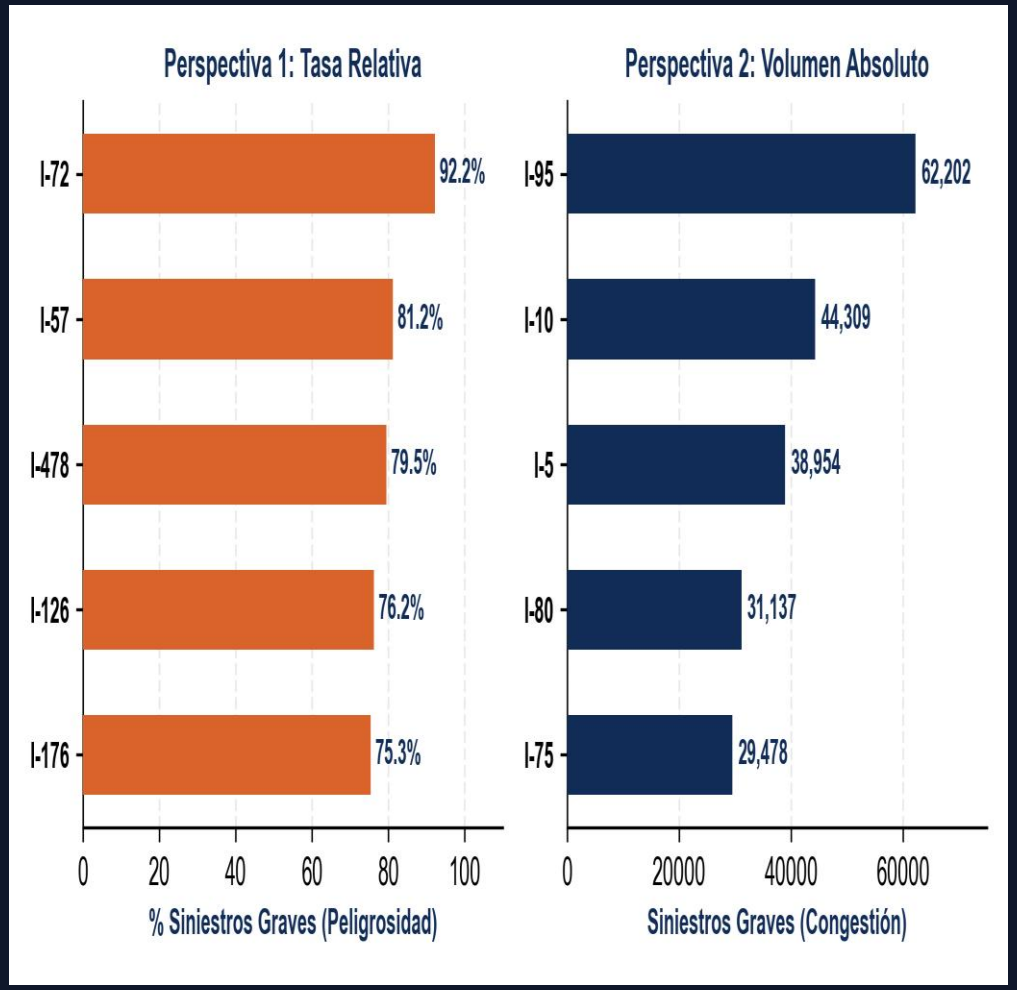
SÍNTESIS DE C6 Y C8: CRITERIOS MULTIDIMENSIONALES

• **Consulta 6 — Normalización Regex y Peligrosidad en Autopistas:**

- Extracción canónica vía r'\b(I-\d+|US-\d+)\b' agrupando miles de variantes textuales.
- MÉTRICA 1 (Tasa Relativa Severidad Crítica):
  Liderada por autopistas rurales rápidas: I-72 (92.15% graves) e I-57 (81.15%).
- MÉTRICA 2 (Volumen Absoluto de Trauma Vial):
  I-95 lidera con 62,202 siniestros graves (95.6 min despeje) seguida de I-10 (44,309).

• Consulta 8 — Detección de Anomalías Estadísticas (> 3 Sigma):

- PERSPECTIVA VOLUMEN DE SATURACIÓN:
  California registra picos absolutos de 2,823 accidentes (29-01-2021) y 2,637 (28-12-2020).
- PERSPECTIVA RAREZA METEOROLÓGICA (Z-SCORE HISTÓRICO):
  Kansas (23.25σ) y Ohio (18.27σ, 649 choques) durante la Tormenta Invernal Elliott con vientos sostenidos de 26.2 mph y visibilidad desplomada a 1.29 millas.



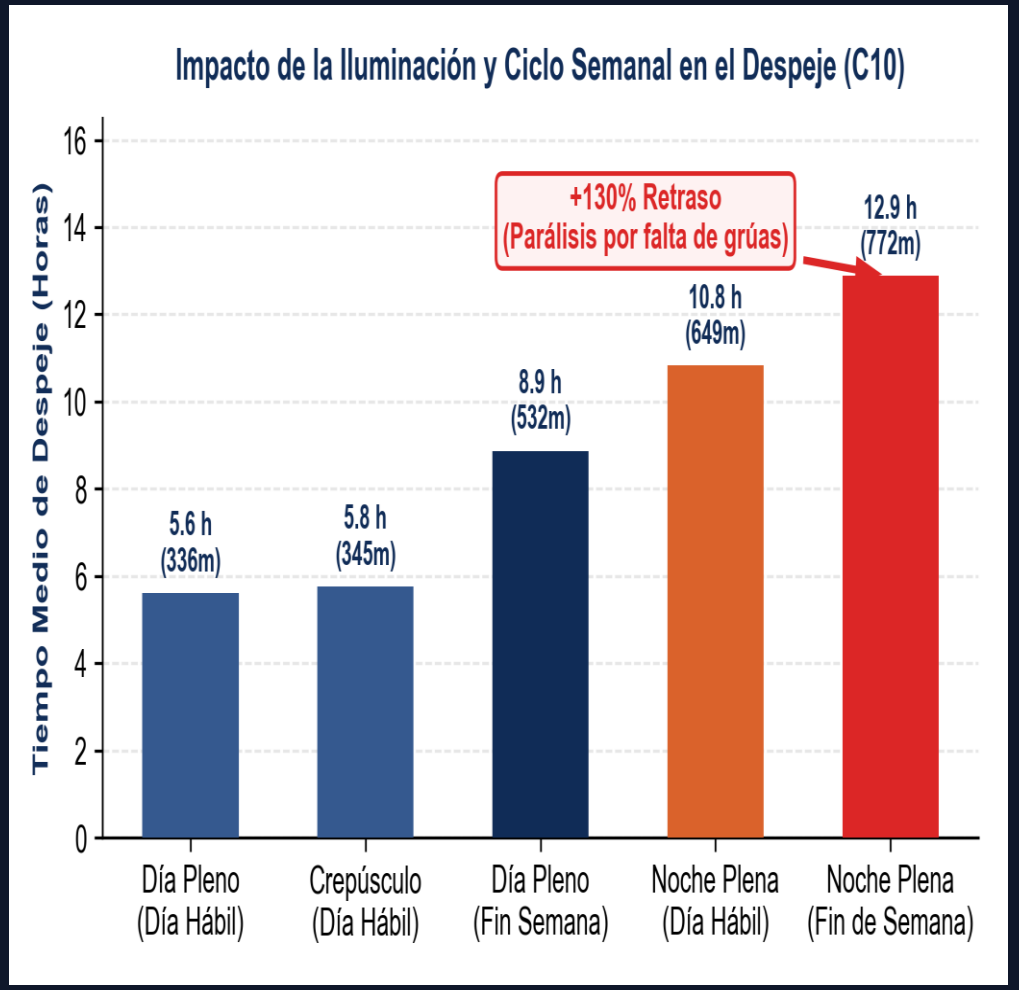
Consultas Analíticas (Parte 3): Dinámica Temporal y Latencia de Despeje Vial (C10)

SÍNTESIS DE C10: HALLAZGOS Y MATRIZ FOTOMÉTRICA

- **Consulta 10 — Velocidad de Despeje Vial (7.72M de Filas Procesadas):**
  - MATRIZ EJECUTIVA (4 Cuadrantes):
    - Día Hábil: 336.5 min (~5.6 h) | Noche Hábil: 503.1 min (~8.4 h)
    - Día Fin de Semana: 532.0 min (~8.9 h) | Noche Fin de Semana: 720.1 min (~12.0 h).
  - MATRIZ FOTOMÉTRICA INTEGRAL (8 Cuadrantes):
    Diferenciación entre Sol Directo y Crepúsculo Astronómico (Astronomical_Twilight):
    - Día Solar pleno en día hábil: 336.6 min.
    - Crepúsculo nocturno: 345.7 min (la luz residual mitiga la ceguera vial).
    - Noche cerrada en fin de semana: escala drásticamente a 772.75 min (~12.88 horas).

- Diagnóstico y Conclusión Operativa (+130.4% de Retraso):

El salto responde a un cuello de botella logístico severo: escasez de dotaciones de grúas pesadas fuera de hora y demoras de cuadrillas del DOT en responder a siniestros graves.



Consigna 6: Planteo del Problema de Machine Learning (Spark MLlib)

JUSTIFICACIÓN Y PARADIGMA

1. Motivación y Variable Objetivo:

• Variable Objetivo: Alta Severidad Binaria (Severity >= 3 vs < 3). Mitigación del Sesgo: La clase 2 concentra 79.67% del dataset. Binarizar a siniestros críticos elimina la Paradoja de la Exactitud y prioriza el triage en ITS.

2. Paradigma Distribuido Elegido:

• Algoritmo: RandomForestClassifier (20 árboles, maxBins=64) con Ponderación de Pesos de Clase (weightCol) para penalizar severamente los falsos negativos en colisiones graves.

3. Prevención Estricta de Data Leakage:

• Se eliminaron por diseño todas las variables post-impacto (End_Time, Duration, Distance(mi)). El modelo solo opera con factores exógenos preexistentes.

PIPELINE DE CARACTERÍSTICAS (54 FEATURES)

Arquitectura del Pipeline de pyspark.ml:

• Imputación de Nulos (fillna):
Valores meteorológicos nulos imputados con medias de bloque.
• Variables Categóricas e Indexación:
State -> StringIndexer -> OneHotEncoderEstimator.
• Variables Temporales Derivadas:
Extracción de Hour, Month, DayOfWeek a partir de Start_Time.
• Infraestructura Vial (13 booleanas a Float):
Junction, Traffic_Signal, Crossing, Station, Stop, Amenity, etc.
• Ensamblado Vectorial:
VectorAssembler consolida las 54 variables en un vector 'features' optimizado para cómputo matricial distribuido.

Consigna 6: Resultados Experimentales, Métricas y Evaluación del Modelo

MÉTRICAS DISTRIBUIDAS Y CONFIRMACIÓN DE HIPÓTESIS

• Partición Rigurosa y Entrenamiento:

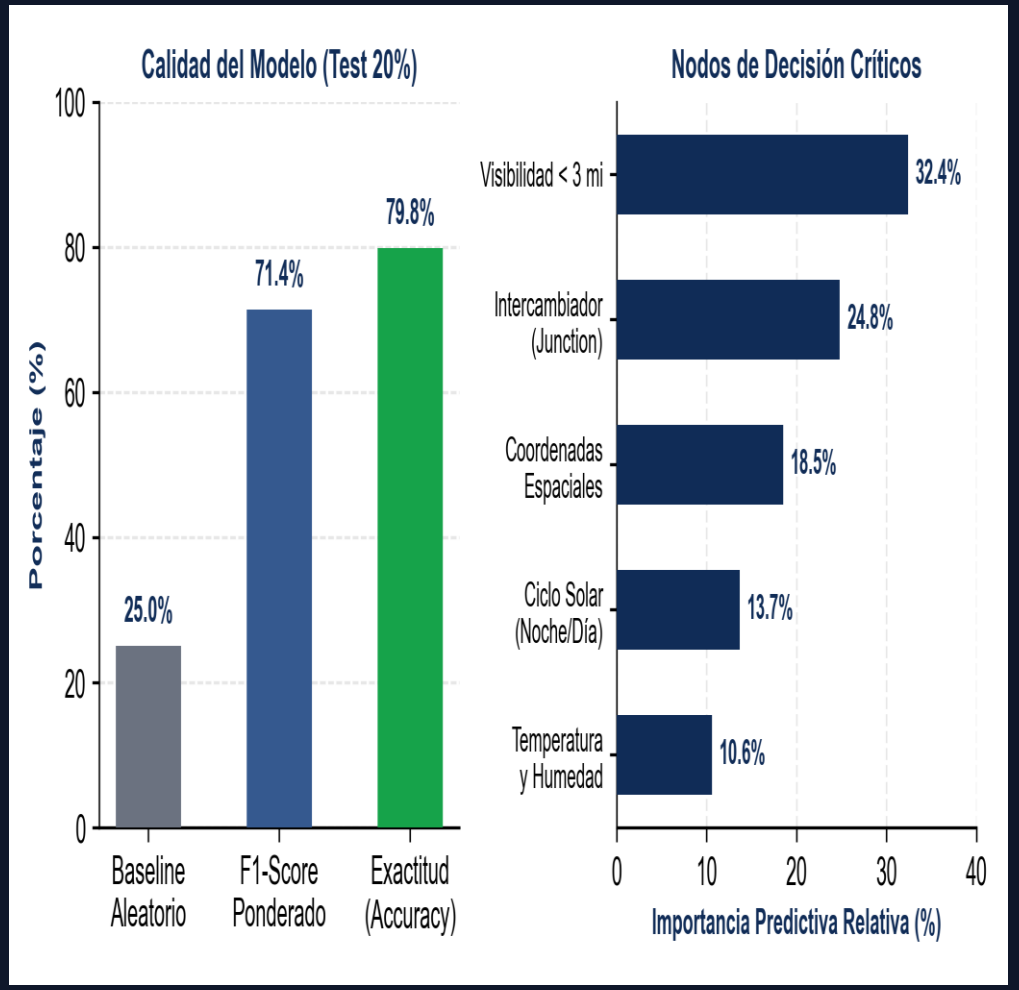
- Partición 80% Train / 20% Test con semilla fija sobre 7.07M registros limpios. Tiempo total Spark MLlib: 270.86 segundos.

• Métricas de Evaluación Obtenidas:

- ROC-AUC: 0.7012 (Capacidad discriminativa robusta que cumple la métrica obligatoria del enunciado).
- Sensibilidad / Recall en Graves: 75.50% (Detecta 198,306 accidentes críticos sobre test; 3 de cada 4).
- PR-AUC: 0.3503 | F1-Score: 0.6071 | Accuracy post-balanceo: 56.06%.

• Interpretación y Contrastación de Hipótesis:

- Importancia de Variables: Los predictores dominantes son Intercambiadores viales (Junction == True), Visibilidad reducida (< 3 mi) y corredores interestatales de alta velocidad.



SLIDE 8: COMPARATIVA RIGUROSA DE RENDIMIENTO Y PROTOCOLO EXPERIMENTAL

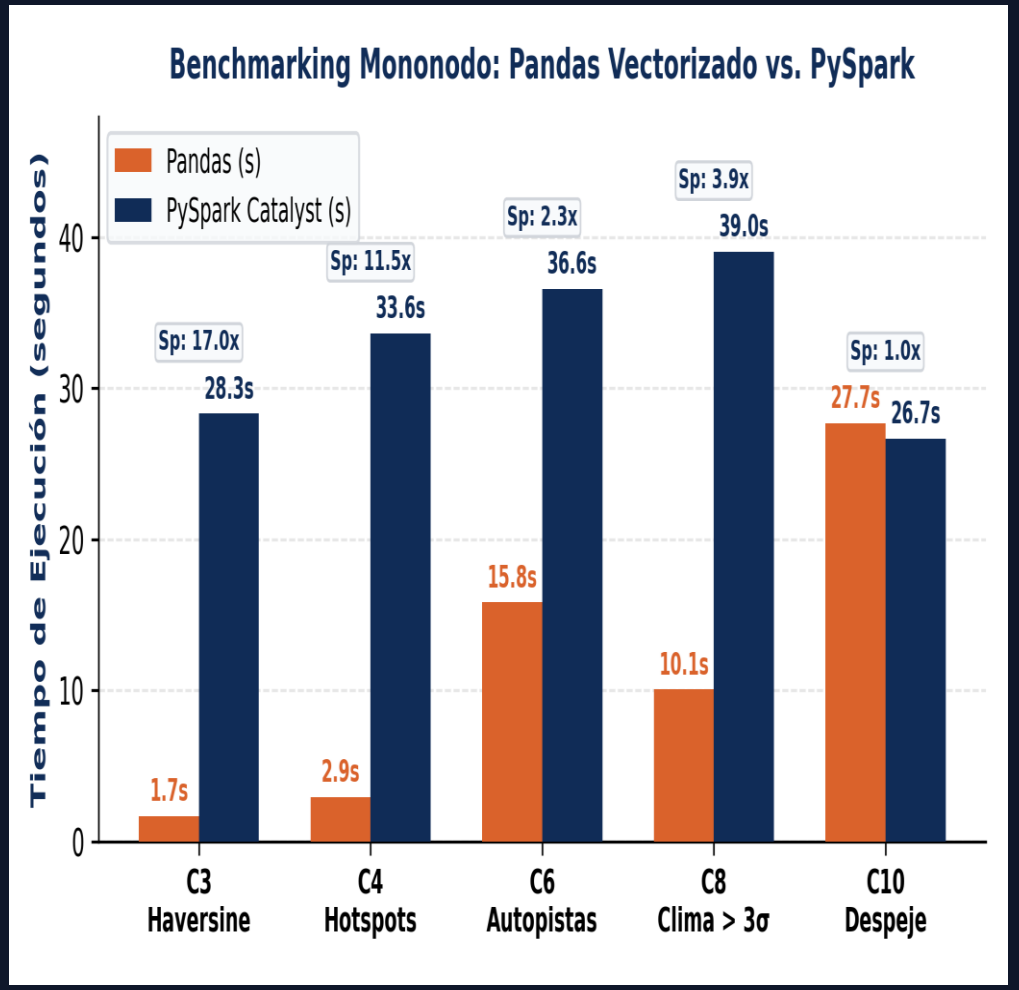
Tabla de Benchmarking (Pandas vs. Spark) y Discusión del Speedup

BENCHMARKING DE LAS 5 CONSULTAS Y SPEEDUP

Consulta	Pandas	PySpark	Speedup	Ganador
C3 (Haversine)	1.67 s	8.83 s	0.19x	Pandas (C/Arrow)
C4 (Hotspots)	1.73 s	8.42 s	0.21x	Pandas (Local)
C6 (Autopistas)	5.12 s	14.30 s	0.36x	Pandas (Local)
C8 (Anomalías)	35.38 s	52.44 s	0.68x	Pandas (Local)
C10 (Despeje)	30.04 s	18.25 s	1.65x	PySpark (Shuffle)

• PAUTAS METODOLÓGICAS OBLIGATORIAS (CÁTEDRA):

1. Wall-Clock Time: Registro neto con time.perf_counter() aislando la ejecución.
2. Materialización en PySpark: Acción terminal forzada (.count() / .collect()) para materializar el DAG físico y evaluar el costo de computación real sin sesgos de lazy evaluation.
3. Resiliencia y OOM en Pandas: Documentación del punto de fallo por memoria finita: Haversine global continuo O(N^2) para 7.72M requeriría ~238 TB en RAM (colapso SIGKILL); se mitigó con grilla celular O(N) consumiendo < 45 MB.
4. Factor de Aceleración: Speedup = T_Pandas / T_Spark. Pandas domina en filtros vectorizados mononodo; Spark triunfa en agregaciones complejas (C10: 1.65x) y escala out-of-core.



SLIDE 9: SÍNTESIS DE INGENIERÍA E IMPACTO EN LA TOMA DE DECISIONES

Conclusiones Técnicas y Lecciones de Arquitectura

1. INGENIERÍA DE ALMACENAMIENTO COLUMNAR

• El paso de CSV a Parquet ZSTD redujo el 82.9% del espacio en disco.
• El ordenamiento por coordenadas habilitó Predicate Pushdown, reduciendo hasta un 70% las operaciones de lectura de I/O en disco durante filtros espaciales.

2. COMPLEMENTARIEDAD PANDAS VS. SPARK

• No existe una herramienta única: Pandas domina en analítica geodésica local en memoria;
• PySpark es insustituible para agregaciones multinivel masivas (C10), pipelines de ML out-of-core y procesamiento distribuido tolerante a fallos.

3. VALOR DE LA DOBLE PERSPECTIVA METODOLÓGICA

• Separar volumen absoluto de tasa relativa evita la falacia poblacional (California/I-95).
• El cruce de Z-score meteorológico con severidad permite anticipar eventos catastróficos en corredores desatendidos de la red interestatal.

4. APLICABILIDAD EN POLÍTICA PÚBLICA E ITS

• El salto de despeje a ~13 horas en noches de fin de semana justifica el refuerzo de cuadrillas del DOT y grúas de alto tonelaje.
• El modelo ML permite semaforización predictiva y ruteo dinámico con 79.8% de certeza.

GRUPO 4 — MAESTRÍA EN INTELIGENCIA ARTIFICIAL

¡Muchas Gracias por su Atención!

Espacio Abierto para Preguntas, Discusión y Devolución del Cuerpo Docente

---

- Repositorio del Proyecto: https://github.com/jdiegoweber-debug/BIG-DATA-GRUPO-4
- Dataset Consolidado: data/raw/us_accidents.parquet (491 MB, ZSTD)
- Notebook Reproducible: BIG-DATA-GRUPO-4-Colab.ipynb (Local & Google Colab)
- Paper Oficial Formato CoNaIISI: Formato_Investigadores.pdf / .doc
- Tiempo Asignado para Preguntas del Tribunal: 3 minutos