UNIVERSIDAD DE PALERMO · MAESTRÍA EN INTELIGENCIA ARTIFICIAL

Big Data · Proyecto final integrador · Defensa oral

Procesamiento distribuido y analítica de accidentes viales en EE. UU. (2016–2023)

Benchmarking de Pandas frente a Apache Spark y clasificación de severidad con Spark MLlib

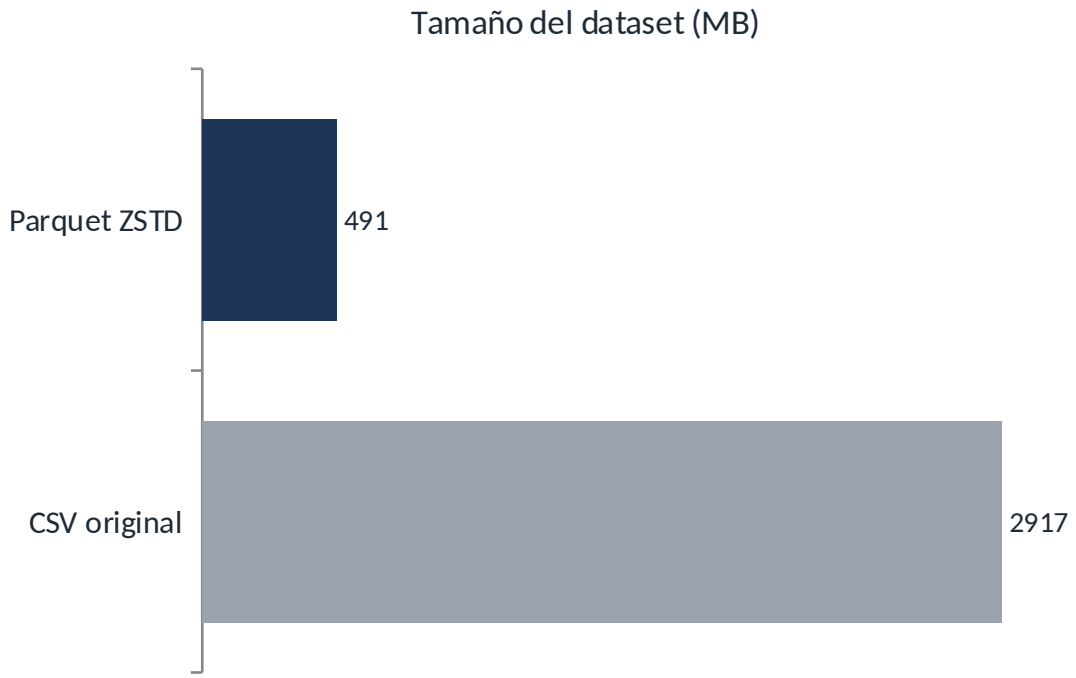
Grupo 4
Diego Diamanti · Melisa Maldonado · Juan Diego Weber
Octubre de 2026

Dataset, arquitectura de almacenamiento y entorno de cómputo

7,73 M
registros (2016–2023)

46
atributos

−83%
tamaño en disco



Decisiones de almacenamiento

- Parquet columnar con compresión ZSTD
- Orden físico por latitud y longitud: bloques agrupados geográficamente
- Estadísticas min/max por bloque: permiten descartar bloques sin leerlos (predicate pushdown)

Entorno de cómputo	Especificación
CPU	Intel Core i5-1135G7 · 4 núcleos / 8 hilos
Memoria	16 GB RAM DDR4
Sistema	Windows 11 Home 64-bit
Software	Python 3.12 · PySpark 3.5.0 · OpenJDK 17 · Pandas + PyArrow

Consultas 3 y 4: búsqueda por radio y puntos más peligrosos

CONSULTA 3 · HAVERSINE, R = 25 KM

Los Ángeles: 361.038 siniestros en el radio

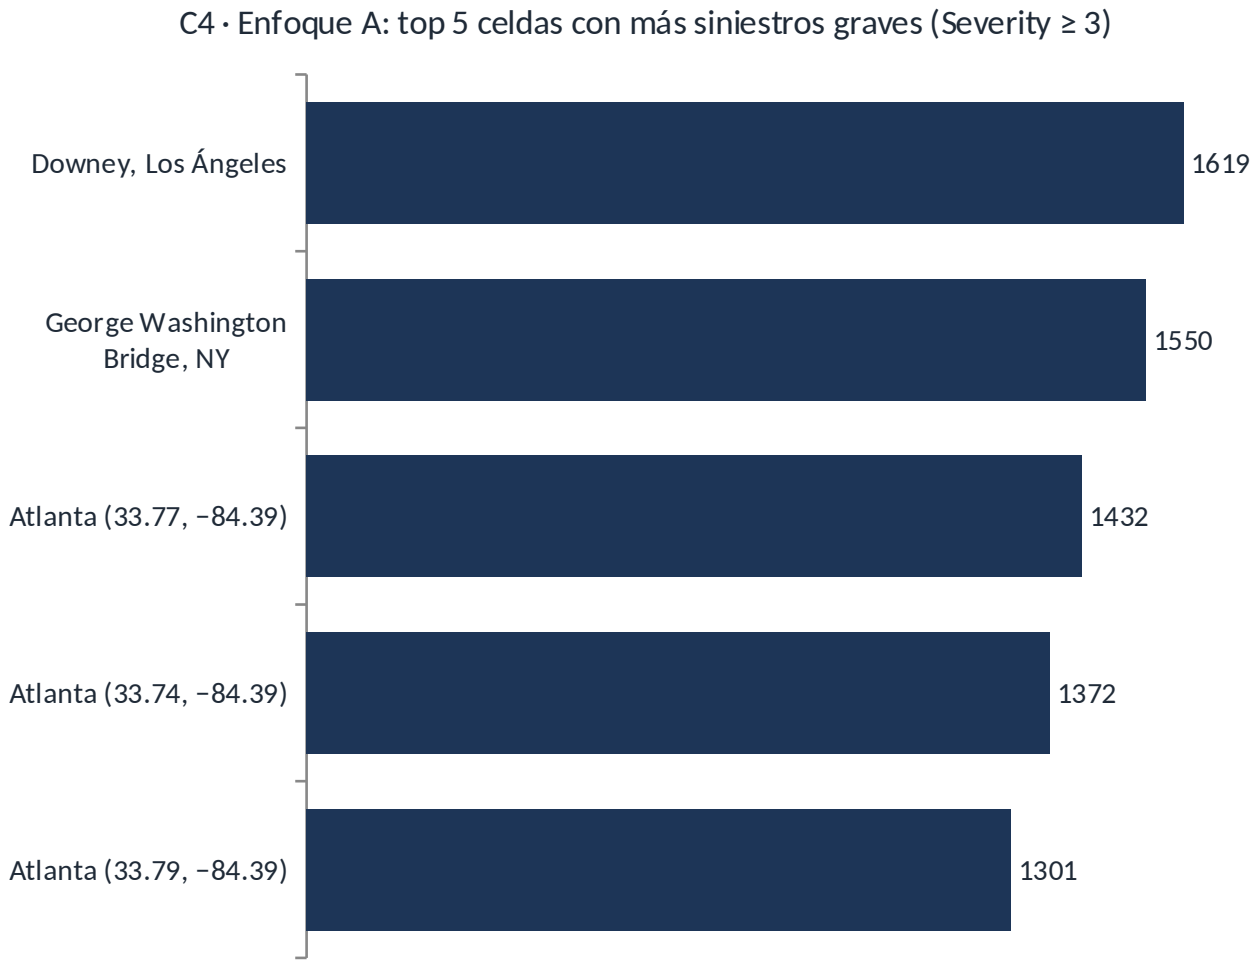
Nueva York: 269.717 siniestros

Resultados idénticos en Pandas y Spark; ordenados por distancia al centro.

CONSULTA 4 · CRITERIO DE PELIGROSIDAD

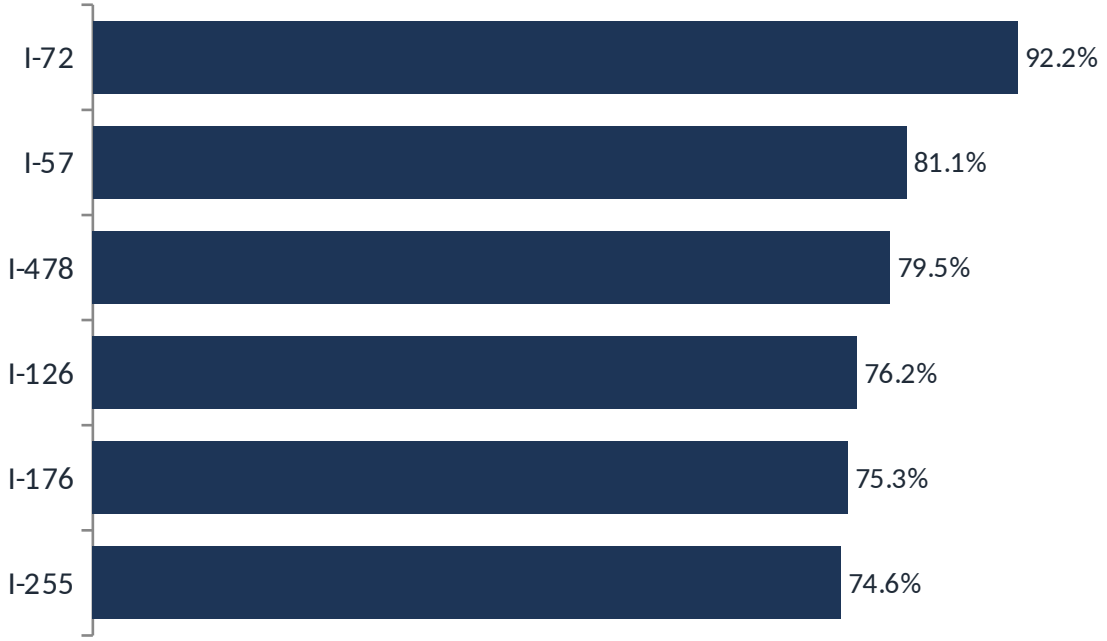
Enfoque A: siniestros con Severity ≥ 3 en celdas de ~2,2 km, a nivel nacional.

Enfoque B: densidad total en celdas de ~5 km en California. Máximo: centro de Los Ángeles, 50.254 siniestros.



Consultas 6 y 8: autopistas críticas y días anómalos

C6 · % de siniestros graves por autopista (top 6)



Vías normalizadas con la expresión regular I-\d+ | US-\d+ (unifica sentidos como «I-95 N» e «I-95 S»).

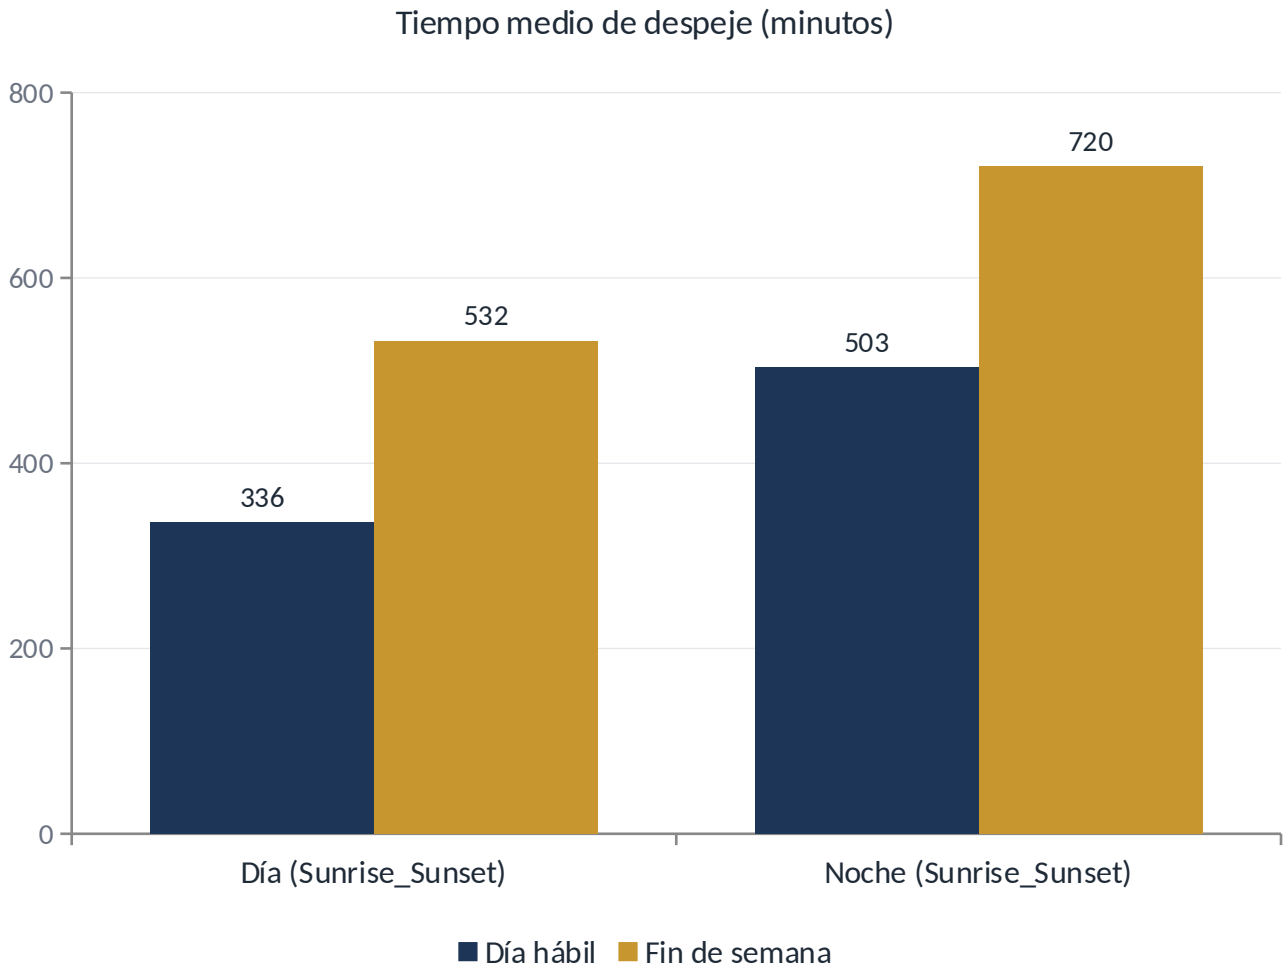
En volumen absoluto lidera la I-95: 62.202 siniestros graves y 95,7 min de despeje promedio.

CONSULTA 8 · DÍAS POR ENCIMA DE 3σ DE LA MEDIA DEL ESTADO

Estado y fecha	Siniestros	Z	Contexto
CA · 29-01-2021	2.823	5,1σ	Mayor volumen absoluto
KS · 18-02-2022	316	23,2σ	Mayor rareza estadística
OH · 23-12-2022	964	18,3σ	Tormenta Elliott: viento 26 mph, visibilidad 1,3 mi
NH · 05-01-2022	101	18,1σ	Visibilidad 2,8 mi

1.171 días anómalos en total. El volumen absoluto lo domina California por población; el Z-score por estado detecta eventos raros en estados con poco tráfico, que el volumen esconde.

Consulta 10: tiempo de despeje según iluminación y tipo de día



5,6 h día hábil con luz solar

12,0 h noche de fin de semana

12,9 h noche cerrada (sin crepúsculo) de fin de semana: 2,3× el día hábil

Explicación posible, no verificada con estos datos: menor disponibilidad de grúas y cuadrillas fuera del horario hábil.

Consigna 6: clasificación de severidad con Spark MLlib

Problema

Predecir Severity (1 a 4) al momento del reporte, para priorizar el despacho de emergencias.

Paradigma

Clasificación supervisada multiclase con DecisionTreeClassifier (maxDepth = 10, maxBins = 60 para los 49 estados).

Sin fuga de información

Se excluyen variables posteriores al impacto: End_Time, duración y Distance(mi).

PIPELINE DE PYSPARK.ML

dropna
nulos en predictores

→

StringIndexer
State, Sunrise_Sunset

→

OneHotEncoder
vectores dispersos

→

VectorAssembler
54 variables

→

DecisionTree
80/20, semilla 42

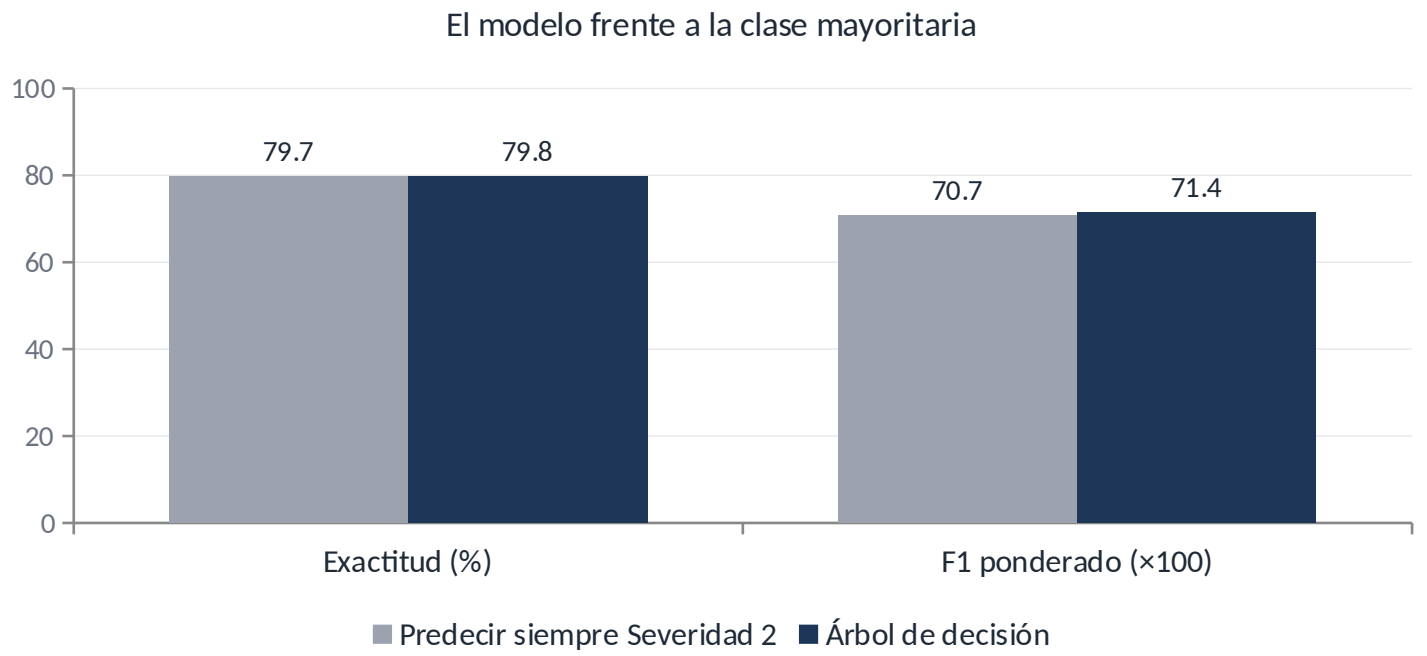
54 variables = 5 numéricas (latitud, longitud, temperatura, humedad, visibilidad) + 48 por estado + 1 por día/noche.

Consigna 6: resultados y evaluación honesta del modelo

79,8% exactitud en test

0,714 F1 ponderado

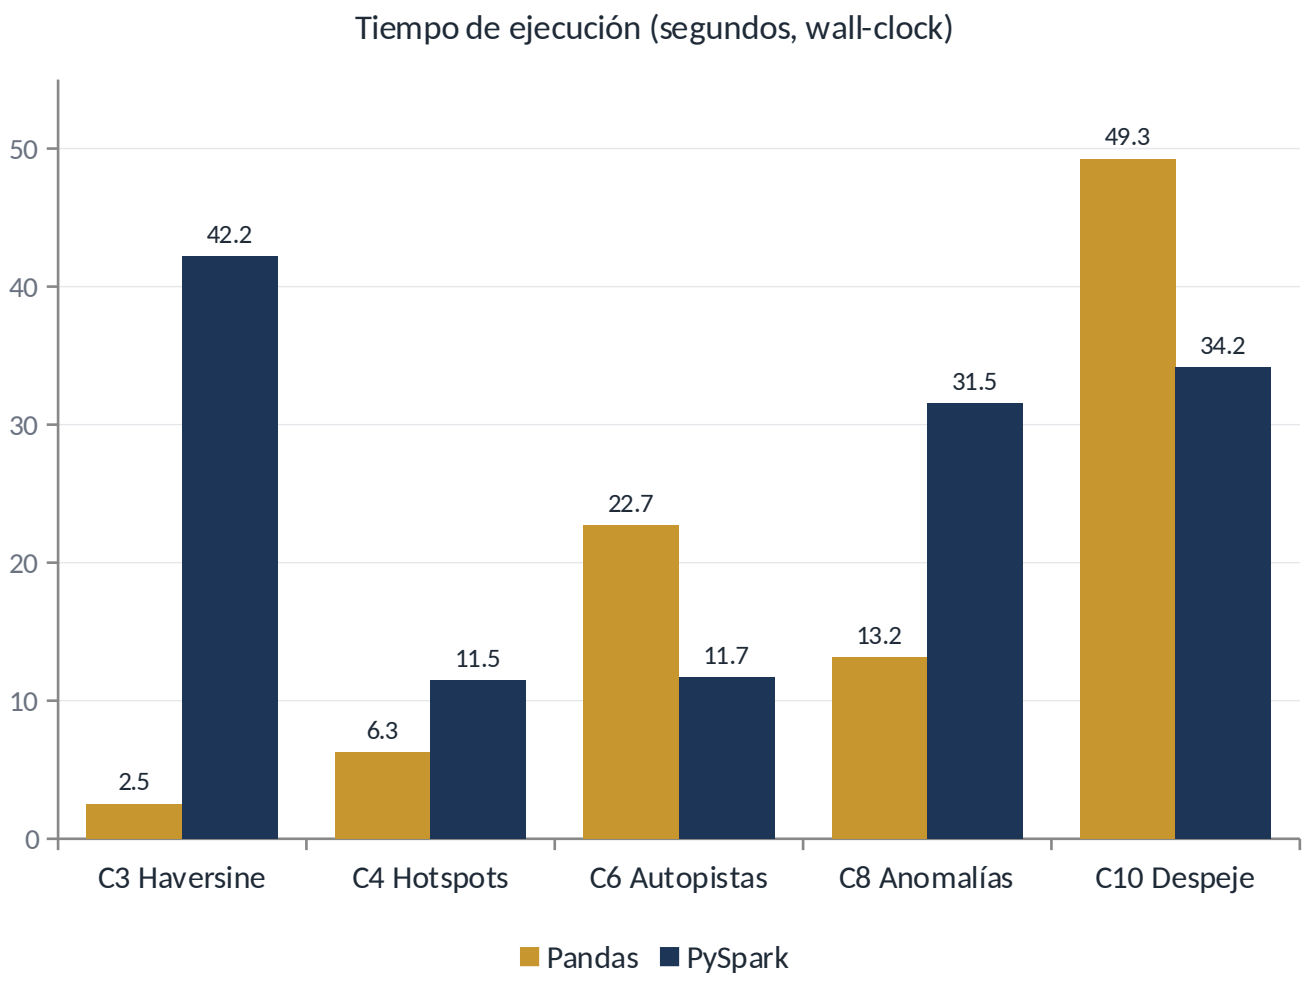
284 s entrenamiento y evaluación



Lectura: la Severidad 2 es el 79,7% del dataset, así que predecirla siempre ya da casi la misma exactitud. El árbol apenas mejora esa referencia: la hipótesis no queda confirmada con estas métricas.

Próximos pasos: reformular como Severity ≥ 3 frente al resto, ponderar clases y reportar ROC-AUC y recall de las clases graves.

Benchmarking: Pandas frente a PySpark en las cinco consultas



Consulta	Speedup	Más rápido
C3	0,06×	Pandas
C4	0,55×	Pandas
C6	1,94×	PySpark
C8	0,42×	Pandas
C10	1,44×	PySpark

Protocolo

- Speedup = T_Pandas / T_Spark (> 1: gana Spark)
- time.perf_counter() y acción terminal en Spark
- OOM evitado: Haversine todos contra todos requeriría ~238 TB; la grilla lo baja a O(N)

Conclusiones técnicas y lecciones de arquitectura

El formato manda

Parquet ZSTD con orden espacial redujo el 83% del tamaño y permitió trabajar en forma interactiva con ambas herramientas.

No hay una herramienta única

Pandas gana en filtros simples que entran en memoria; Spark gana cuando hay regex, agrupaciones y shuffle (C6, C10) y es la opción para escalar fuera de un nodo.

Dos perspectivas por consulta

Separar volumen absoluto de tasa relativa evita conclusiones sesgadas por población (California, I-95).

Cuidado con el desbalance

Una exactitud de 80% no alcanza cuando una clase es el 80% de los datos: hay que comparar contra la clase mayoritaria.

Gracias. ¿Preguntas?

Código reproducible
github.com/diegodiamanti-droid/BIG-DATA-GRUPO-4

Notebook
BIG-DATA-GRUPO-4-Colab.ipynb (local y Google Colab)

Artículo
Plantilla institucional Formato_Investigadores